

Un fichier csv

```
nom;naiss;deces;mots_clés;nat;prenom;sexe  
Jobs;1955;2011;Apple;USA;Steve;H  
Turing;1912;1954;Décryptage;GB;Allan;H  
Packard;1912;1996;HP;USA;David;H  
Dijkstra;1930;2002;Graphes;NL;Edsger;H  
Turing;1912;1954;Décryptage;GB;Allan;H  
Hopper;1906;1992;Compilateur;USA;Grace;F
```




Comma-Separated Values, connu sous le sigle CSV, est un format informatique ouvert représentant des données séparées par des virgules (dans les versions anglo-saxonnes) ou des points-virgules dans des versions européennes.

Un fichier CSV est un fichier texte, par opposition aux formats dits « binaires ».

Chaque ligne du texte correspond à une ligne d'un tableau de données et les virgules (ou points-virgules) correspondent aux séparations entre les colonnes.

Les portions de texte séparées par une virgule correspondent ainsi aux contenus des cellules du tableau.



Importation et Exploitation en Python

```
histoire=[  
{'nom':'Jobs','naiss':1955,'deces':2011,'mots_clés':'Apple','nat':'USA','prenom':'Steve','sexe':'H'},  
{'nom':'Turing','naiss':1912,'deces':1954,'mots_clés':'Décryptage','nat':'GB','prenom':'Allan','sexe':'H'},  
{'nom':'Packard','naiss':1912,'deces':1996,'mots_clés':'HP','nat':'USA','prenom':'David','sexe':'H'},  
{'nom':'Dijkstra','naiss':1930,'deces':2002,'mots_clés':'Graphes','nat':'NL','prenom':'Edsger','sexe':'H'},  
{'nom':'Turing','naiss':1912,'deces':1954,'mots_clés':'Décryptage','nat':'GB','prenom':'Allan','sexe':'H'},  
{'nom':'Hopper','naiss':1906,'deces':1992,'mots_clés':'Compilateur','nat':'USA','prenom':'Grace','sexe':'F'}  
]
```



Les données structurées en tables peuvent être stockées dans des fichiers au format CSV. Même si cette méthode de stockage de l'information peut s'avérer pratique dans certains cas précis, elle peut s'avérer rudimentaire dans un contexte de données pléthoriques et disparates. Il est souvent souhaitable d'utiliser une base de données pour stocker et exploiter des données apparaissant sur plusieurs tables distinctes

I. BASES DE DONNEES



Le terme base de données est apparu au début des années 60. C'est l'apparition des disques durs à la fin des années 50 qui a permis d'utiliser les ordinateurs pour stocker et manipuler des données. Avec l'apparition du Web, la quantité de données à stocker a littéralement explosé. Aujourd'hui, la plupart des sites internet (du petit site personnel au grand site d'e-commerce) utilisent au moins une base de données. Les bases de données jouent un rôle fondamental dans notre monde devenu numérique où il est extrêmement facile de dupliquer l'information.

Exo 1. Trouver des exemples de domaines d'activité où les bases de données jouent un rôle primordial.



Dans une base de données, l'information est stockée dans des fichiers, mais à la différence des fichiers au format CSV, il n'est pas possible de travailler sur ces données avec un simple éditeur de texte. Pour manipuler les données présentes dans une base de données (consulter, enrichir ou mettre à jour), il est nécessaire d'utiliser langage spécifique.

Communément et historiquement, on parle de bases de données (BD) dès lors que l'on définit :

- Un modèle ou une structure de données,
- Un langage de manipulation de ces données qui permet l'interrogation et la mise à jour de ces données

Rq 1. On dispose en général alors d'un "système de gestion de base de données" abrégé en SGBD.



Il existe différents types de bases de données, par exemple, les bases de données hiérarchiques, les bases de données objet, les bases de données nosql ou bien encore les bases de données relationnelles. Les bases de données relationnelles sont le plus utilisées au monde, c'est ce type de base de données que nous allons étudier.

II. MODELE RELATIONNEL

1. RELATION



Les bases de données relationnelles ont été mises au point en 1970 par Edgar Franck Codd, informaticien britannique (1923-2003). Ces bases de données sont basées sur la théorie mathématique des ensembles.



La notion de relation est au cœur des bases de données relationnelles.

a) Entités et attributs

Une **relation** peut être vue comme un tableau à 2 dimensions, composé d'un en-tête et d'un corps.

L'en-tête contient les intitulés des attributs, le corps contient les données proprement dites

Le corps est lui-même composé de


d'**entités** (sous forme de **n-uplets**) disposés en **lignes**

et d'attributs disposés en colonnes.

Rq 2. On emploie aussi le terme "table" à la place de "relation" et d' "**enregistrement**" à la place d' "entité"

Exemple 1 : la relation LIVRES

id	titre	auteur	ann_publi	note
1	1984	Orwell	1949	10
2	Dune	Herbert	1965	8
3	Fondation	Asimov	1951	9
4	Le meilleur des mondes	Huxley	1931	7
5	Fahrenheit 451	Bradbury	1953	7
6	Ubik	K.Dick	1969	9
7	Chroniques martiennes	Bradbury	1950	8
8	La nuit des temps	Barjavel	1968	7
9	Blade Runner	K.Dick	1968	8
10	Les Robots	Asimov	1950	9
11	La Planète des singes	Boulle	1963	8
12	Ravage	Barjavel	1943	8
13	Le Maître du Haut Château	K.Dick	1962	8
14	Le monde des A	Van Vogt	1945	7
15	La Fin de l'éternité	Asimov	1955	8
16	De la Terre à la Lune	Verne	1865	10



b) Domaine d'un attribut

Pour chaque attribut d'une relation, il est nécessaire de définir un **domaine** : le domaine d'un attribut donné correspond à un ensemble fini ou infini de valeurs admissibles.

Exemple 2 : le domaine de l'attribut "id" correspond à l'ensemble des entiers (la colonne "id" devra obligatoirement contenir des entiers).

le domaine de l'attribut "titre" correspond à l'ensemble des chaînes de caractères .

le domaine de l'attribut "note" correspond à l'ensemble des entiers positifs.

Exo 2. Quel peut-être le domaine de l'attribut "auteur" ?



Au moment de la création d'une relation, il est nécessaire de renseigner le domaine de chaque attribut.

Le SGBD s'assurera que les attributs de chaque enregistrement ajouté à une relation respectent bien les domaines correspondants : si par exemple vous essayez d'ajouter une note non entière (par exemple 8,5), le SGBD signalera cette erreur et n'autorisera pas l'écriture de cette nouvelle donnée.

c) Clé primaire

Autre contrainte importante dans les bases de données relationnelles : l'absence de doublons. (une relation ne peut pas contenir deux enregistrements identiques.)

Exemple 3 : Le SGBD devrait donc empêcher la génération de la table suivante :

id	titre	auteur	ann_publi	note
1	1984	Orwell	1949	10
2	Dune	Herbert	1965	8
2	Dune	Herbert	1965	8
3	Fondation	Asimov	1951	9

Exo 3. Comment procéder alors si l'on souhaite référencer les deux exemplaires d'un même livre ?



Afin de respecter cette contrainte sur les doublons, on définit la notion de "clé primaire".

Une **clé primaire** est un attribut ou un ensemble d'attributs dont la valeur permet d'identifier de manière unique un enregistrement de la relation. **On ne peut donc pas trouver dans toute la relation deux fois la même valeur pour les attributs qui constituent la clé primaire**

Exemple 4 : Si on se réfère à l'exemple de la relation ci-dessous :

Relation LIVRES

id	titre	auteur	ann_publi	note
1	1984	Orwell	1949	10
2	Dune	Herbert	1965	8
3	Fondation	Asimov	1951	9
4	Le meilleur des mondes	Huxley	1931	7
5	Fahrenheit 451	Bradbury	1953	7
6	Ubik	K.Dick	1969	9
7	Chroniques martiennes	Bradbury	1950	8
8	La nuit des temps	Barjavel	1968	7
9	Blade Runner	K.Dick	1968	8
10	Les Robots	Asimov	1950	9
11	La Planète des singes	Boulle	1963	8
12	Ravage	Barjavel	1943	8
13	Le Maître du Haut Château	K.Dick	1962	8
14	Le monde des Â	Van Vogt	1945	7
15	La Fin de l'éternité	Asimov	1955	8
16	De la Terre à la Lune	Verne	1865	10

- L'attribut "note" peut-il jouer le rôle de clé primaire ?
- L'attribut "ann_publi" peut-il jouer le rôle de clé primaire ?
- L'attribut "auteur" peut-il jouer le rôle de clé primaire ?
- L'attribut "titre" peut-il jouer le rôle de clé primaire ?
- Le couple d'attributs ("auteur", "titre") peut-il jouer le rôle de clé primaire ?



Il reste donc l'attribut "id", qui n'existe essentiellement que pour jouer le rôle de clé primaire. En effet, à chaque fois qu'un roman est ajouté à la relation, son "id" correspond à l'incrément de l'id (id du nouveau=id de l'ancien+1) du roman précédemment ajouté. Il est donc impossible d'avoir deux romans avec le même id. Ajouter un attribut "id" afin qu'il puisse jouer le rôle de clé primaire est une pratique courante (mais non obligatoire) dans les bases de données relationnelles. Dans le cas précis qui nous intéresse, il aurait été possible de ne pas utiliser d'attribut "id", car chaque livre édité possède un numéro qui lui est propre : l'ISBN, cet ISBN aurait donc pu jouer le rôle de clé primaire.

Exo 4.

On donne un extrait d'une relation référençant des films :

Relation FILMS

id	titre	realisateur	ann_sortie	note_sur_10
1	Alien, le huitième passager	Scott	1979	10
2	Dune	Lynch	1985	5
3	2001 : l'odyssée de l'espace	Kubrick	1968	9
4	Blade Runner	Scott	1982	10

.....

- Quels sont les différents attributs de cette relation.
- Donner le domaine de chaque attribut.
- Pour chaque attribut dire si cet attribut peut jouer le rôle de clé primaire

2. MODELISATION RELATIONNELLE



On souhaite maintenant enrichir la relation LIVRES en ajoutant des informations supplémentaires sur les auteurs, nous obtenons alors :

Relation LIVRES_AUTEURS

id	titre	nom_auteur	prenom_auteur	date_nai_auteur	langue_ecriture_auteur	ann_publi	note
1	1984	Orwell	George	1903	anglais	1949	10
2	Dune	Herbert	Frank	1920	anglais	1965	8
3	Fondation	Asimov	Isaac	1920	anglais	1951	9
4	Le meilleur des mondes	Huxley	Aldous	1894	anglais	1931	7
5	Fahrenheit 451	Bradbury	Ray	1920	anglais	1953	7
6	Ubik	K.Dick	Philip	1928	anglais	1969	9
7	Chroniques martiennes	Bradbury	Ray	1920	anglais	1950	8
8	La nuit des temps	Barjavel	René	1911	français	1968	7
9	Blade Runner	K.Dick	Philip	1928	anglais	1968	8
10	Les Robots	Asimov	Isaac	1920	anglais	1950	9
11	La Planète des singes	Boulle	Pierre	1912	français	1963	8
12	Ravage	Barjavel	René	1911	français	1943	8
13	Le Maître du Haut Château	K.Dick	Philip	1928	anglais	1962	8
14	Le monde des Â	Van Vogt	Alfred Elton	1912	anglais	1945	7
15	La Fin de l'éternité	Asimov	Isaac	1920	anglais	1955	8
16	De la Terre à la Lune	Verne	Jules	1828	français	1865	10

Exo 5. Peut-on se satisfaire longtemps d'une telle table ? Proposer une amélioration possible.

a) Relier des Relations

Relation AUTEURS

id	nom	prenom	ann_naissance	langue_ecriture
1	Orwell	George	1903	anglais
2	Herbert	Frank	1920	anglais
3	Asimov	Isaac	1920	anglais
4	Huxley	Aldous	1894	anglais
5	Bradbury	Ray	1920	anglais
6	K.Dick	Philip	1928	anglais
7	Barjavel	René	1911	français
8	Boulle	Pierre	1912	français
9	Van Vogt	Alfred Elton	1912	anglais
10	Verne	Jules	1828	français



Relation LIVRES

id	titre	id_auteur	ann_publi	note
1	1984	1	1949	10
2	Dune	2	1965	8
3	Fondation	3	1951	9
4	Le meilleur des mondes	4	1931	7
5	Fahrenheit 451	5	1953	7
6	Ubik	6	1969	9
7	Chroniques martiennes	5	1950	8
8	La nuit des temps	2	1968	7
9	Blade Runner	6	1968	8
10	Les Robots	3	1950	9
11	La Planète des singes	8	1963	8
12	Ravage	2	1943	8
13	Le Maître du Haut Château	6	1962	8
14	Le monde des Â	9	1945	7
15	La Fin de l'éternité	3	1955	8
16	De la Terre à la Lune	10	1865	10



Dans la relation LIVRES : l'attribut "auteur" a été remplacé par un attribut "id_auteur".



L'introduction d'une relation AUTEURS et la mise en place d'une connexion entre cette relation et la relation LIVRES permettent d'éviter la redondance d'informations. La connexion est établie **entre la clé primaire** de la relation AUTEURS et **une clé dite étrangère** de la relation LIVRES.

Pour établir un lien entre 2 relations R_A et R_B , on ajoute à R_A un attribut a qui prendra les valeurs de la clé primaire de R_B . Cet attribut a est appelé **clé étrangère** (cette clé correspond à la clé primaire d'une autre table).

b) Schéma relationnel

Le schéma relationnel présente l'ensemble des relations présentes dans une base de données. Il doit donc comporter les informations suivantes :



Les noms des différentes relations




pour chaque relation, la liste des attributs avec leur domaine respectif



pour chaque relation, la clé primaire et éventuellement la clé étrangère

Exemple 5 : pour les relations LIVRES et AUTEURS :

AUTEURS(id, nom, prenom, ann_naissance, langue_ecriture)
 LIVRES(id, titre, #id_auteur, ann_publi, note)



Rq 3. Les attributs soulignés sont des clés primaires, le # désigne une clé étrangère.

c) Contraintes d'intégrité

Une contrainte d'intégrité est une propriété logique dont la vérification par les données en garantit la cohérence.

Contraintes de domaine



Chaque attribut respecte son domaine.

Contraintes de relation :



Chaque entité est unique (c'est donc une contrainte garantie par l'existence d'une clé primaire.)

Contraintes de référence :



Toutes les valeurs prises par la clé étrangère correspondent bien à des valeurs présentes dans la clé primaire

Rq 4. Certains SGBD ne vérifient pas cette contrainte (et ne renvoient donc aucune erreur en cas de problème), ce qui peut provoquer des comportements erratiques.

Contraintes utilisateurs :



Des contraintes sur le contenu des attributs (restriction du domaine en fonction de la nature des informations donnée par un attribut)

Par ex., on peut évoquer la présence de l'arobase ('@') dans un attribut désignant une adresse mail, ou bien un entier compris entre 0 et 200 pour un âge (une plage plutôt raisonnable).

Exo 6. On donne la relation FILMS ci-dessous,

Relation FILMS

id	titre	realisateur	ann_sortie	note_sur_10
1	Alien, le huitième passager	Scott	1979	10
2	Dune	Lynch	1985	5
3	2001 : l'odyssée de l'espace	Kubrick	1968	9
4	Blade Runner	Scott	1982	10

- créer une relation REALISATEURS (attributs de la relation REALISATEURS : id, nom, prenom et ann_naissance, vous trouverez toutes les informations nécessaires sur le Web).
- Modifier la relation FILMS afin d'établir un lien entre les relations FILMS et REALISATEURS. Préciser l'attribut qui jouera le rôle de clé étrangère.

c. Donner le schéma relationnel de la base de données ainsi définie.

3. **Exos**

Exo 7. Bulletins BD

Donner la modélisation relationnelle des bulletins scolaires. Cette modélisation doit permettre de mentionner

- Des élèves, possédant un numéro d'étudiant alphanumérique unique,
- Un ensemble de disciplines fixées (non données)
- Au plus une note sur 20, par matière et par élève.

On prendra soin de préciser toutes les contraintes utilisateurs qui ne peuvent être inscrites dans les schémas relationnels.

Rq 5. Il est possible de définir une **clé primaire** dite **composite** à partir du couple (ou du n-uplet) formé par deux (ou n) attributs.

Exo 8.

La modélisation de bulletin consiste en 3 relations :

Elève(*nom* String, *prénom* String, *numéro* String)

Disciplines(*intitulé* String, *id* Int_)

Note (*num eleve* String, *id disc* Int_, *note* Float)

Parmi les ensembles suivant, quels sont ceux qui constituent des relations valides pour la base de données BULLETINS :

- ELEVE = {}
DISCIPLINE = {}
NOTE={}
- ELEVE = {('Hobo', 'Bob', 'AB12345')}
DISCIPLINE = {('NSI', 0), ('EPS', 1)}
NOTE={ ('AB12345', 1, 17)}
- ELEVE = {('Hobo', 'Bob', 'AB12345')}
DISCIPLINE = {('NSI', 0)}
NOTE={ ('AB12345', 1, 17)}
- ELEVE = {('Hobo', 'Bob', 'AB12345')}
DISCIPLINE = {('NSI', 0)}
NOTE={ ('AB12345', 0, 17), ('AB12345', 0, 18)}
- ELEVE = {('Hobo', 'Bob', 'AB12345')}
DISCIPLINE = {('NSI', 0), ('EPS', 1)}
NOTE={ ('AB12345', 0, 17), ('AB12345', 1, 17)}

Exo 9. Véloc-BD

Un loueur de vélo souhaite utiliser une SGBD pour gérer les locations.

Un vélo est défini par un numéro de location (unique), une taille (e.g. 24 pouces) et une couleur.

Un client possède un prénom et un numéro de téléphone (unique).

Lorsqu'un vélo est loué à un client, on sauvegarde la durée de la location.

Après avoir schématisé les associations de ce problème, proposer le modèle relationnel correspondant.

Exo 10. On considère la base de données d'une bibliothèque :

- LIVRE(N°Livre, Titre, Auteur, Editeur)
- EXEMPLAIRE(N°Livre, N°Exemplaire, Disponible)
- ADHERENT(N°Adhérent, Nom, Prénom, Adresse, Mail, Phone)
- PRET (N°Livre, N°Exemplaire, N°Adhérent, DateEmprunt, DateRetour)

Dresser le schéma relationnel en précisant les clés primaires et les clés étrangères



On pourra utiliser un domaine de type **Date** (de la forme jour/mois/année), voire de type **Time** (de la forme heure : minute : seconde)

Exo 11. Garage BD

Un garagiste souhaite mettre en place une SGBD pour lister toutes les voitures (déjà immatriculées) à vendre. Une voiture possède une immatriculation unique, une marque et un modèle (e.g. "AB123CD", "Renault", "twingo"). Les voitures possèdent également une ou plusieurs couleurs.

Pour le garagiste, un client est caractérisé par son nom, son compte bancaire (unique) et son numéro de téléphone.

Lorsqu'un client achète une voiture, le prix et la date de l'achat sont sauvegardés.

Après avoir schématisé les associations de ce problème, proposer le modèle relationnel correspondant.

Exo 12. Spectacle-BD

Une salle de spectacle possède un nom (unique), est située dans une ville et propose des spectacles.

Un spectacle possède un titre, un producteur et une année de création (titre et producteur permettent d'identifier le spectacle).

Un spectateur possède un numéro d'adhérent et un nom.

Lorsqu'un spectateur choisit un spectacle dans une salle, on sauvegarde une date et un prix.

Après avoir schématisé les associations de ce problème, proposer le modèle relationnel correspondant.

Exo 13. Départements-BD

Modéliser les informations sur les départements français. Pour chaque département on veut pouvoir stocker son nom, son code, sa préfecture et la liste des départements voisins.

Exo 14. Proposer un schéma conceptuel (des relations sous forme de boîtes connectées entre elles) puis traduire en schéma relationnel de la base de données décrite ci-dessous.

Une personne désire modéliser une base de données correspondant aux réceptions qu'elle organise (personnes invitées, menus,...). Cette base de données doit lui permettre, entre autres choses, de pouvoir l'aider à organiser une réception en lui offrant la possibilité de construire sa liste d'invités, ainsi que son menu et les vins associés.

- Une réception a lieu à une date donnée et y sont invitées des personnes dont on connaît le nom, le prénom, le sexe, l'âge et la profession (l'identification d'une personne se fait par son nom et son prénom).
- Le repas servi lors d'une réception comprend un certain nombre de plats identifiés par leur nom ("poulet à la mexicaine" par exemple) et leur nature ("entrée froide", "dessert" par exemple).
- Pour pouvoir réussir un menu, il faut que les vins servis soient en accord avec les plats. On dispose donc pour chaque plat d'une liste de types de vins possibles caractérisés par leur région viticole ("bourgogne" par exemple) et un type ("rouge corsé", "blanc sec" par exemple).
- Pour que la réception soit réussie, il faut éviter qu'une dispute vienne gâcher l'événement et pour se faire la connaissance des amitiés et inimitiés entre personnes est primordiale.
- Enfin, le dernier ingrédient d'une réception réussie est d'offrir au menu des plats que les invités apprécient et surtout d'éviter de leur servir des plats qu'ils détestent.

III. SYSTEME DE GESTION DE BASES DE DONNEES (SGBD) RELATIONNEL

Le SGBD concilie des objectifs et des contraintes



Accès aux données :

Le SGBD intègre le langage d'accès à la base. Il est crucial que le langage permette d'obtenir des réponses aux requêtes en un temps raisonnable. Le langage doit donc être optimisé et minimiser les accès disques de façon transparente pour l'utilisateur.



Cohérence des données :

le SGBD garantit les contraintes d'intégrité.

C'est au moment de la création de la table que l'on précisera les attributs et leur domaine, le type de clé éventuel et les contraintes utilisateurs éventuels que le SGBD se chargera de vérifier.



Sécurité des données :

le SGBD permet également de gérer les autorisations d'accès à la base de données. Il est en effet souvent nécessaire de contrôler les accès par exemple en permettant à l'utilisateur A de lire et d'écrire dans la base de données alors que l'utilisateur B aura uniquement la possibilité de lire les informations contenues dans cette même base de données.



Partage des données :

Plusieurs personnes peuvent avoir besoin d'accéder aux informations contenues dans une base données en même temps. Cela peut parfois poser problème, notamment si les 2 personnes désirent modifier la même donnée au même moment (on parle d'accès concurrent). Ces problèmes d'accès concurrent sont aussi gérés par les SGBD.



Résistance aux pannes :

Les fichiers des bases de données sont stockés sur des disques durs dans des ordinateurs, ces ordinateurs peuvent subir des pannes. Il est souvent nécessaire que l'accès aux informations contenues dans une base de données soit maintenu, même en cas de panne matérielle. Les bases de données sont donc dupliquées sur plusieurs ordinateurs afin qu'en cas de panne d'un ordinateur A, un ordinateur B contenant une copie de la base de données présente dans A, puisse prendre le relais. Tout cela est très complexe à gérer, en effet toute modification de la base de données présente sur l'ordinateur A doit entraîner la même modification de la base de données présente sur l'ordinateur B. Cette synchronisation entre A et B doit se faire le plus rapidement possible, il est fondamental d'avoir des copies parfaitement identiques en permanence. C'est aussi le rôle des SGBD qui assurent donc la maintenance des différentes copies de la base de données.

Rq 6. Il existe une multitude de SGBD : des gratuites, des payantes, des libres ou bien encore des propriétaires.